

数理推論タスクにおける学習・推論パイプラインの構築

本郷颯人¹ 加地翔太² 小谷真士³ 嶋中雄大⁴
宮川裕貴⁵ 中島悠樹¹ 安孫子リク¹ 松田公慶⁶
¹東京大学 ²独立研究者 ³大阪公立大学
⁴芝浦工業大学 ⁵中京大学 ⁶筑波大学
連絡先: 本郷颯人

概要

本研究は、「第2回大規模言語モデルのファインチューニング技術と評価 (FT-LLM 2026)」チューニングコンペティションの数学タスクにおける取り組みを報告する。競技で与えられた 8B ベースモデルを出発点とし、32 層から 48 層への深さ拡張による 12B 級モデル化、最大系列長 16384 の長文 CoT によるフルパラメータ SFT、および GRPO による強化学習を組み合わせて数理推論能力の向上を図った。最終提出系では、多数決によるテストタイムスケールングを中核とし、開発用評価データセットでは文字列正規化を併用した Wait=1 条件で $\text{cons@40} = 0.96$ を記録した。一方、コード実行を伴うツール統合推論や外部大規模モデルによる判定は、主にデータ選別やオフライン分析に留まり、最終提出システムには含めなかった。

1 はじめに

近年、大規模言語モデル (LLM) は自然言語処理の多岐にわたる分野で目覚ましい成果を挙げている。しかし、厳密かつ多段階の論理展開が要求される数理推論タスクにおいては、依然としてハルシネーションや計算ミスが発生しやすく、LLM にとって最も難易度の高い領域の一つとされている。この課題を克服するため、良質な Chain of Thought (CoT) データを用いた教師ありファインチューニング (SFT) や、人間の評価またはルールの下でモデルを最適化する強化学習 (RLHF 等) といったファインチューニング技術の重要性が急速に高まっている。

我々のチームでは、「第2回大規模言語モデルのファインチューニング技術と評価 (FT-LLM 2026)」チューニングコンペティションの数学タスクにおける取り組みを報告する。本タスクの課題設定は、コンペティション運営から与えられた 80 億パラメータのベースモデルである LLM-jp-4-instruct を対象に、日本語で出題される日本の中学校・高等学校レベルの数学問題に対する推論能力を向上させることである。比較的小規模なモデルにおいて、限られた計算資源の中でいかにして高度な数理的思考能力を獲得させ、正確な解答を導き出すかが主なターゲットとなる。

この課題に対し、我々のチームでは学習から推論に至る一連のパイプラインを構築した。まず、主力と

して採用した数学 CoT データセットに対して、大規模モデルによる自動審査、ルールベース・正規表現による異常解答の除外、および生成タグの整形といった手法でデータキュレーションを行い、質の高い学習データを厳選した。加えて、TIR (Tool Integrated Reasoning) 用データセットでは、Python コード実行環境を用いた実行可能性の検証も試みた。次に、複雑な推論過程やコード生成に対応できるよう長文コンテキストを考慮した SFT を実施し、基礎的な解答能力を付与した。さらに、学習の安定化とフォーマット遵守、および推論ステップの最適化を目的として、GRPO (Generative Reward Policy Optimization) による強化学習を適用した。最終提出システムでは、推論時に多数決 (Majority Voting) を中核とする構成を採用し、TIR や外部判定はオフライン分析・評価に用いた。本稿では、これらの統合的なアプローチの詳細とその評価結果について述べる。




図 1: 提案手法の全体像

提案手法は、学習時の改善と推論時のスケールングを段階的に積み上げる構成であり、その全体像を図 1 に示す。

2 関連研究

2.1 LLM における数理推論能力の向上

大規模言語モデル (LLM) に複数ステップを要する複雑な数学問題を解かせるための画期的な手法として、中間的な推論過程を言語化して出力させる Chain of Thought (CoT) プロンプティング [1] が提案され、モデルの数理推論能力が劇的に向上することが実証された。さらに、強力なクロードモデルが持つ推論能力を比較的小規模なモデルに蒸留・移植するための教師ありファインチューニング (SFT) も盛んに研究されている。SFT の成否はデータセットの質と量に大きく依存するため、大規模な合成データの構築が重要なアプローチとなっている。その代表例として、Mixtral モデルを用いて 180 万件もの数学的推論データと複数パターンの正答パスを生成した OpenMathInstruct-1 [2] などが挙げられる。本研究の初期段階においても、こうした先行研究に倣い、厳選された合成データセットを用いた SFT を実施している。

2.2 推論プロセスに対する強化学習

SFT による模倣学習の限界を超え、モデル自身が自律的に正しい推論パスを探索するための手法として、強化学習 (RL) の適用が近年著しい成果を上げている。DeepSeekMath 等で導入された GRPO (Generative Reward Policy Optimization) [3] は、同一プロンプトから生成された複数の出力群 (グループ) 内で報酬を正規化することにより、従来の PPO (Proximal Policy Optimization) で必要とされた価値モデルを省略し、メモリ消費を抑えつつ安定した最適化を可能にした。さらに、数学やプログラミングのように正解が客観的に検証可能なタスクにおいては、人間の評価の代わりにルールベースの正誤判定を報酬として与える RLVR (Reinforcement Learning with Verifiable Reward) [4] が極めて有効であることが示されている。本研究でも、これらの強化学習の枠組みを採用し、フォーマットの遵守と推論ステップの最適化を図っている。

2.3 テストタイムスケール

近年の LLM 研究においては、学習時の計算資源を増やすだけでなく、推論時の計算資源をスケールさせることで精度を劇的に向上させるパラダイムが注目を集めている。その基礎となる強力な手法が、サンプリング温度を上げて多様な推論パスを複数生成し、その中で最も多く導出された解答を最終出力とする多数決 (Majority Voting / Self-Consistency) [5] である。また直近の動向として、推論時の思考ステップを意図的に拡張させ、モデルに自己検証や修正を促すアプローチも提案されている。例えば s1 [6] などの研究では、推論時にモデルの生成を強制的に延長させる Budget Forcing 等のシンプルな手法によって推論時の計算量をコントロールし、テストタイムスケールの恩恵を効率的に引き出している。本研究のシステム構築においても、これらの知見を応用し、提出系では多数決を基盤とし

つ、コード実行や外部判定は補助的な分析系として位置づけた。

3 数理推論に向けた学習パイプライン (提案手法 1)

本章では、競技で与えられた 80 億パラメータの LLM に対し、高度な数理推論能力を付与するための学習パイプラインについて述べる。本アプローチは、厳格なデータキュレーション、長文コンテキストを考慮した教師ありファインチューニング (SFT)、そして強化学習 (GRPO) による推論プロセスの最適化という 3 つの段階で構成される。

1. データキュレーション

処理: CoT は自動審査とルールベース整形で、TIR 用データは Python 実行可否で検証する。
狙い: ノイズの少ない推論データを構築する。

2. SFT

処理: 長文 CoT と出力フォーマットをフルパラメータ学習する。
狙い: 中間思考と最終解答を安定して生成させる。

3. GRPO

処理: フォーマット報酬と正答報酬で推論を最適化する。
狙い: 深い推論探索と正答率の両立を図る。

図 2: 学習パイプラインの各段階

図 2 は、本研究の学習パイプラインを 3 段階に整理したものである。

3.1 データセットの構築とフィルタリング

LLM に複雑な数理推論の過程 (Chain of Thought; CoT) を学習させるため、大規模な合成データセットの収集と厳密な選別を行った。最終的に主力として採用したのは、約 560 万件規模の大規模 CoT データセットと、約 175 万件規模の補助 CoT データセットであり、これに加えて約 130 万件の TIR 専用データセットも整備した。重要なのは、Python コード実行環境を用いた検証が行われたのは TIR 用データセットのみであり、最終提出の主力となった CoT データセットには適用していない点である。

主力として採用した CoT データセットでは、既存の合成データに含まれる論理的飛躍や計算ミス、不自然な出力を抑えるために、大規模モデルによる自動審査とルールベースのクリーニングを組み合わせた。まず、生成済みの問題と解答に対して別の審査役モデルで自動判定を行い、誤答と判断されたサンプルを除外した。加えて、ルールベース・正規表現により、LaTeX の形式としては成立していても数学の答えとして不自然な文字列 (例: `\text{does not exist}`) を出力しているサンプルを除去した。さら

に、最終回答以前に残る不要な生成タグや思考プロセスを整形・除去し、学習に適した形式へ統一した。

一方で、TIR (Tool Integrated Reasoning; ツール統合推論) 用データセットでは、LLM が生成した Python コードをサンドボックス環境で実行し、標準エラーやタイムアウトを起こさなかったかどうか、すなわち実行可能性フラグを基準とした独自のフィルタリングを行った。この実証的な検証は TIR 用データセット固有のものであり、CoT 主力データセットの品質担保は前述の自動審査とルールベース整形によって行った。

一方で、ライセンスおよび競技ルールの観点から、一部の公開数学データセットは採用しなかった。特に、大規模商用モデルからの蒸留由来である可能性があるものや、著作権上の懸念が大きいコンテスト問題由来のデータは不採用とした。また、評価用に用いた日本語訳ベンチマークについては、非公開テストの代理ベンチマークとして扱い、SFT データ生成時にはホワイト/ブラックリスト運用により使用不可データを弾く方針を採った。

3.2 教師ありファインチューニング (SFT)

構築した高品質データセットを用い、ベースモデルに対する SFT を実施した。最終的に比較した長文 SFT モデルでは、ベースモデルを 12B 規模へ層拡張した上で、最大系列長 16384 の長文 CoT データに対するフルパラメータ SFT を行った。深さ拡張は、既存の層対応表に基づき、前半 16 層をそのまま保持しつつ、元の後半層を奇数番目へ再配置し、偶数番目の新規層 (16, 18, ..., 46) を隣接層間の Optimal Transport 補間で初期化する形で 48 層へ拡張した。さらに、挿入層の `self_attn.o_proj` と `mlp.down_proj` はゼロ初期化されている。学習環境には ABCI 3.0 の 1 ノード (NVIDIA H200 × 8 GPU) を用いた。一方で、TIR 用データセットに対する SFT は最終的に未着手であり、提出モデルの学習には用いていない。

数理推論タスクでは、複雑な問題になるほど中間的な思考プロセスが長大化する。事前実験において、デフォルトの短いコンテキスト長では推論の途中で生成が打ち切られる (Truncation) 問題が発生し、モデルが最終的な解答に到達できず学習が不安定になる現象が確認された。これに対処するため、学習コンフィグにおいてコンテキスト長を 16384 まで拡張して SFT を行い、長大な思考プロセスを最後まで破綻なく生成しきれるようにモデルを適応させた。公開されている長文 SFT 設定ファイルの主なハイパーパラメータは、以下の通りである。

- `learning_rate`: 4.0e-5
- `per_device_train_batch_size`: 1
- `gradient_accumulation_steps`: 32
- `num_train_epochs`: 1
- `optim`: adamw_torch
- `lr_scheduler_type`: cosine_with_min_lr
- `warmup_ratio`: 0.03
- `max_grad_norm`: 0.2

データについては補助 CoT データセットを中心に少なくとも 175 万件規模、最終的には 250 万件以上の CoT データを投入した。またプロンプト設計において、モデルに思考プロセスと最終的な解答を明確に分離させるためのフォーマット (例: `<think>...</think>` タグの使用や、`\boxed{}` による解答の囲み) を指定し、推論構造の定式化を促した。

3.3 強化学習 (GRPO) による最適化

SFT によって基礎的な解答能力とフォーマットの遵守能力を獲得したモデルに対し、推論ステップのさらなる最適化と自律的な探索能力 (Deep Thinking) の向上を目的として、GRPO を適用した。最終的な GRPO モデルは、長文 SFT モデルを初期ポリシーとして、強化学習フレームワーク上で 1725 ステップ学習したものである。

GRPO における報酬関数は、主に 2 つの要素から設計した。1 つ目は、`\boxed{}` などの指定フォーマットを正しく出力できているかを評価するフォーマット報酬であり、2 つ目は、数式パーサーを用いて最終的な解答が正解と一致しているかを判定する正答 (Outcome) 報酬である。実装は強化学習フレームワークに基づき、12B 用の学習設定では、主に以下の条件を用いた。

- `num_unique_prompts_rollout`: 8
- `num_samples_per_prompt_rollout`: 32
- `response_length`: 7168
- `pack_length`: 8192
- `learning_rate`: 1e-6
- `beta`: 0.00
- `seed`: 3
- `num_epochs`: 1

この設定では rollout バッチサイズは $8 \times 32 = 256$ となる。

GRPO の学習過程においては、モデルがより長く深い推論を探索するようになるため、生成トークン数が急増してメモリ不足 (OOM: Out of Memory) を引き起こしやすくなる。これに対し、本研究では学習環境における生成と最適化のノード・GPU 割り当ての調整、コンテキスト長拡張を施した SFT モデルからの学習再開、および長文生成時のペナルティや Wait パラメータによる調整といった学習安定化の工夫を取り入れた。特に GRPO では、おおむね 700 ステップまでは中規模 CoT データセットを用い、それ以降はスループット低下を防ぐため大規模 CoT データセットに切り替えるカリキュラム的運用を行った。学習終盤および推論設定に関しては、以下の値を比較・採用した。

- 学習終盤の Temperature: 1.018
- clip_higher: 0.272
- 12B モデルの rollout バッチサイズ: 256
- 比較した Wait 値: 0, 1, 2, 3
- 開発評価での最高値: 文字列正規化を併用した Wait=1 条件で cons@40 = 0.96

12B モデルの rollout バッチサイズは vLLM の KV キャッシュ制約を考慮した設計になっている。

4 推論・評価システムの実装 (提案手法 2)

本研究では、学習フェーズでのモデル性能向上 (Train-time Scaling) に加え、推論フェーズにおける計算資源のスケーリング (Test-time Scaling) を通じて最終的な正答率を最大化するシステムを構築した。提出系では、サンプリングによる多数決 (Majority Voting / Self-Consistency) を中核とする推論パイプラインを実装した。一方で、外部ツールを用いた回答検証メカニズムであるツール統合推論 (TIR) は、主にオフライン評価・分析のために検証した。

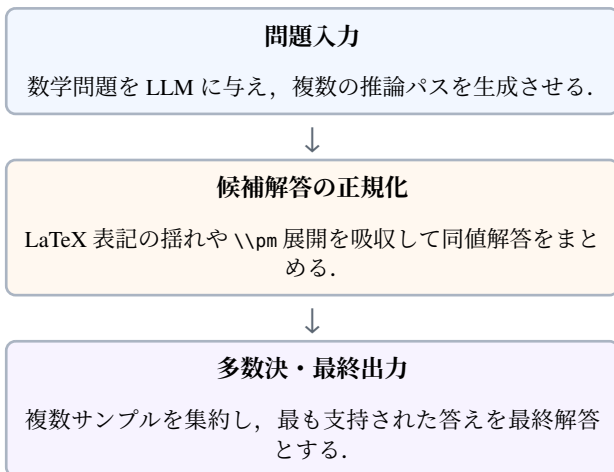


図 3: 最終提出ファイルにおける推論システムの流れ

図 3 は、最終提出ファイルで採用した多数決推論の処理フローを示す。TIR はこのフローには含めておらず、オフライン評価・分析に限定して用いた。

4.1 ツール統合推論 (TIR)

LLM 単独での推論では、複雑な四則演算や高次方程式の求根などにおいて、論理展開は正しいものの途中の計算ミスによって最終的な解答を誤るケースが散見される。この課題を解決するため、LLM によるコード生成と安全なサンドボックス環境でのコード実行を組み合わせた TIR システムを導入した。

本システムでは、既存のツール統合推論基盤に近いアーキテクチャを参考に、LLM サーバーとサンドボックスを共存させた。推論を制御するオーケストレーター、LLM、そして分離された実行環境が相互に連携し、LLM が必要に応じて生成した Python

コードをサンドボックスで実行する。実行結果 (標準出力やエラーログ) は再び LLM にフィードバックされ、LLM はその客観的な計算結果に基づいて推論を補正・続行する。

ただし、TIR を組み込んだ評価用モデルは、主催者提供の開発用評価データセット 100 問に対する独自評価で pass@1 = 0.86 と高い性能を示した一方、無限ループや統合コスト、出力の不安定化といった課題が残った。この評価はサンドボックス環境上で数式同値判定器を用いて算出したものであり、カテゴリ別の内訳は以下の通りである。

カテゴリ	pass@1
中 1	93.3%
中 2	94.4%
中 3	75.0%
IA	80.0%
IIB	88.4%
IIIC	80.0%

表 1: TIR 評価モデルのカテゴリ別 pass@1

そのため、TIR は安定性や統合コストの課題から最終提出システムには含めず、オフライン評価・分析およびデータクリーニングに用いた。

4.2 多数決 (Majority Voting) による解答抽出

テストタイムスケーリングの恩恵を最大限に引き出すため、単一の推論パス (Greedy Decoding) による解答抽出 (pass@1) ではなく、多数決アルゴリズムを推論システムに組み込んだ。提出系の評価では、同一の入力に対して多様な思考プロセスを伴う複数回答を生成させ、その中で最も多く導出された解答を最終的な出力として採用した。開発評価で最高スコアを記録した代表条件は以下の通りである。

- サンプリング温度: 0.7
- 最大生成長: 16384
- サンプル数: 40
- Wait パラメータ: 1
- 併用した後処理: 空白および $\pm$ 展開の正規化
- 集約法: cons@40

この条件で、100 問の開発用評価データセットに対する推論は約 960 秒で完了した。

多数決を機能させる上で最大の課題となったのが、LLM が生成する LaTeX 形式の数式表記の揺れである。例えば、数学的には完全に等価な数式であっても、空白やカンマの有無、あるいは $\pm$ の展開といった出力フォーマットの揺れによって、単純な文字列一致では別々の解答として集計されてしまう問題が発生した。

この集計割れを防ぐため、抽出された解答の文字列に対し、不要な空白の削除や特定の記号 ($\pm$ 等)

を正規化する後処理を実装した．一方で、複雑な数式の等価性判定やパース処理に対する外部大規模モデルによる判定の導入も検討したが、最終的には中止となり、提出システムに組み込むには至らなかった．

5 実験と評価

5.1 実験設定

本研究で構築した学習・推論パイプラインの有効性を検証するため、2種類のデータセットを用いて評価を行った．1つ目は、コンペティション運営から提供された開発用評価データセット（100問）、2つ目は、より難易度が高く汎化性能を測るための外部日本語訳数学ベンチマークである．開発用評価データセットのカテゴリ別内訳は以下の通りである．

カテゴリ	問題数
中 1	15
中 2	18
中 3	16
数 IA	15
数 IIB	26
数 IIIC	10

表 2: 開発用評価データセットのカテゴリ別問題数

評価指標としては、単一の推論結果における正解率（pass@1）と、k 回のサンプリング結果から多数決を行って得られた最終解答の正解率（cons@k）を用いた．なお cons@1 は定義上 pass@1 と等価であり、本稿の表では cons@1 に統一して示す．評価時の一致判定には数式同値判定器による normalized match を用い、必要に応じて文字列正規化の後処理を適用した．評価設定は以下の通りである．

- Temperature: 0.7
- 最大生成長: 16384
- サンプル数: 40
- 比較した Wait パラメータ: 0, 1, 2, 3
- 最高スコアの条件: Wait=1 + 空白・\pm 正規化
- 推論環境: ABCI 3.0 の 1 計算ノード（NVIDIA H200 GPU 8 基搭載、RAM 2TB）

100 問に対する cons@40 推論は約 960 秒で完了し、500 問換算でも約 80 分であり、競技制約の 500 分以内に十分収まる．

5.2 定量評価結果

ベースモデル、長文 SFT モデル、および GRPO モデルの性能比較を行った．まず開発用評価データセットにおける結果を見ると、ベースモデルの cons@1=0.440 に対し、長文対応の SFT を施したモデルでは 0.840 へと大きく向上した．さらに、GRPO を適用した最終モデルでは cons@1=0.870 に達し、SFT から GRPO への移行によっても改善が確認された．

次に、テストタイムスケーリング（多数決）の効果を検証した結果、GRPO モデルでは条件によって cons@40 が 0.89~0.96 の範囲で変動し、最高値 0.96 は Wait=1 と空白・\pm 正規化を併用した条件で観測された．一方、Wait=0 系の条件では cons@40 は 0.89~0.91 に留まった．また、外部日本語訳数学ベンチマークにおいてもベースモデルの pass@1=22.2% に対し、SFT モデルで 38.6%、GRPO モデルでは 71.0% と大幅な改善が見られ、本提案手法が未知の難問に対しても一定の頑健性を持つことが示された．開発用評価データセットは 100 問であるため、1 間差が 1% に相当する点には留意が必要である．

指標	Base	SFT	GRPO
cons@1	0.440	0.840	0.870
cons@20	0.660	0.920	0.950
cons@40	0.680	0.930	0.960
cons@80	0.720	0.920	-
cons@160	0.770	0.920	0.950

表 3: 開発用評価データセットにおける主要な比較結果

条件	cons@40	備考
Wait=0 系	0.89–0.91	複数の評価ログで確認された範囲
Wait=1 + 文字列正規化	0.96	最高値

表 4: Wait 条件と正規化の比較（GRPO, cons@40）

性能比較の要点を表 3 にまとめる．列数を抑えた転置表とすることで、Base, SFT, GRPO の差分が読み取りやすくなった．また Wait 条件のうち、記録上確認できた主要な比較を表 4 に示した．開発評価で最も高い cons@40 は、Wait=1 と文字列正規化を併用した条件で観測された 0.96 であった．

5.3 定性評価とエラー分析（アブレーション）

定量的に高いスコアを達成した一方で、いくつかの技術的課題とモデルの傾向が定性分析から明らかになった．

評価スクリプトのフォーマット不一致問題

推論結果の評価において、ルールベースの数式パーサーが正解を不正解（False Negative）として誤判定するケースが散見された．具体的には、模範解答 $(1 \pm \sqrt{97}) / 12$ に対して出力が $1/12 - \sqrt{97}/12$ のように等価変形される場合、あるいは \pm の前後の半角スペースやカンマの有無が異なる場合である．また、模範解答が $(x, y) = (4, 2)$ であるのに出力が 4 のみであったような、形式上の欠落も見られた．本システムではこの揺れを吸収するため、多数決の集計前に \pm の展開や空白除去を行う後処理を導入した．一方、外部大規模モデルによる判定の導入も検

討したが、最終的には中止となり、提出システムには組み込まれなかった。

コンテキスト長と Wait パラメータの影響

Wait パラメータの影響を調査した結果、開発評価で最も高い cons@40 は Wait=1 と文字列正規化を組み合わせた条件で観測された 0.96 であった。一方、Wait=0 系の条件では cons@40 は 0.89~0.91 に留まった。Wait パラメータを増やすと、回答前に“Wait”を追加して再生成させるため思考を引き延ばせる一方、出力長の増大によってトークン制限(16384 トークン等)に近づくトレードオフがある。そのため、本タスクでは Wait 値そのものよりも、文字列正規化を含む後処理と組み合わせた設定全体で性能を評価する必要があることが示された。

分野別の得意・不得意

カテゴリ別および単元別の正答率を分析した結果、中学レベルの数学（中 2: 18 問中 72.2%, 中 1: 15 問中 66.6%）や、高校数学の一部である「微分法・積分法」（75.0%）において高い推論能力を示した。一方で、「数学 IIB」（26 問中 23.0%）や「数学 IA」（15 問中 26.6%）全体ではスコアが低迷しており、特に「三角関数」（0.0%）や「指数・対数」（0.0%）といった、純粋なテキストベースの思考だけでは代数的な式変形が極めて複雑になる分野を苦手としている傾向が浮き彫りになった。

6 おわりに

本稿では、「第 2 回大規模言語モデルのファインチューニング技術と評価」チューニングコンペティションの数学タスクにおいて、80 億パラメータのベースモデルの数理推論能力を向上させるための統合的なアプローチを提案し、その有効性を実証した。

本研究の結論として、比較的小規模なモデルであっても、学習から推論に至るパイプラインを精緻に設計することで、高度な数理的思考能力を獲得できることが明らかになった。具体的には、主力として採用した CoT 学習データに対して、大規模モデルによる自動審査、ルールベース・正規表現による異常解答の除外、および生成タグの整形を組み合わせたデータキュレーションを行い、長文コンテキストに対応した教師ありファインチューニング (SFT) と、フォーマットと正答に基づく報酬を用いた強化学習 (GRPO) を組み合わせることで、モデルの自律的な推論探索能力を引き出すことに成功した。さらに、最終提出系では多数決を中核とする推論を採用した。一方で、TIR や外部大規模モデルによる判定は、主にオフライン評価・分析に留まり、今後の課題として残った。

今後の課題としては、より複雑で長大な推論を必要とする問題に対応するため、学習・推論の双方におけるさらなる長文コンテキストへの適応と、それに伴う Truncation 問題の完全な解決が挙げられる。ま

た、TIR についても、無限ループや統合コスト、不安定な出力といった課題が残っており、LLM が自律的にコードを実行して自己修正を行うプロセスのさらなる安定化が重要な検討事項である。最後に、本研究で構築した高品質データによる SFT と GRPO、そして推論スケールアップのパラダイムは、数学タスクに留まらず、プログラミングや論理パズルといった他の推論集約型タスクへの応用可能性も高く、今後のさらなる展開が期待される。

謝辞

本研究では, 産業技術総合研究所の AI 橋渡しクラウド (ABCI 3.0) の計算資源を利用した. また, コンペティションを主催された国立情報学研究所 (NII) に感謝する.

参考文献

- [1] J. Wei ほか, 「Chain-of-Thought Prompting Elicits Reasoning in Large Language Models」, Advances in Neural Information Processing Systems, 2022, pp. 24824–24837.
- [2] S. Toshniwal と others, 「OpenMathInstruct-1: A 1.8 Million Math Instruction Tuning Dataset」, arXiv preprint arXiv:2402.10176, 2024.
- [3] Z. Shao ほか, 「DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models」, arXiv preprint arXiv:2402.03300, 2024.
- [4] D. Guo ほか, 「DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning」, arXiv preprint arXiv:2501.12948, 2025.
- [5] X. Wang ほか, 「Self-Consistency Improves Chain of Thought Reasoning in Language Models」, The Eleventh International Conference on Learning Representations, 2023.
- [6] N. Muennighoff と others, 「s1: Simple Test-Time Scaling」, arXiv preprint arXiv:2501.19393, 2025.